

Análisis Factorial - Psicología

Karina Itzel Rodríguez Conde

2022-04-21

Introducción

El Análisis Factorial consiste en reducir la dimensionalidad de los datos originales, explicando un conjunto de variables observadas por un pequeño número de **variables latentes** o no observadas, llamados *factores*. Los factores se construyen para explicar las covarianzas o las correlaciones entre las variables, además de presuponer un modelo estadístico formal.

Descarga de paquetes y librerías

```
install.packages("psych")
```

```
library(psych)
```

```
install.packages("polycor")
```

```
library(polycor)
```

```
install.packages("ggcorrplot")
```

```
library(ggcorrplot)
```

Matriz de trabajo

Para esta práctica, se trabajó con la matriz **bfi** del paquete *psych*, la cual se encuentra precargada en R.

1.- Extracción de datos

```
x <- bfi
```

Exploración de la matriz

1.- Dimensión

```
dim(x)
```

```
## [1] 2800 28
```

Esta base de datos contiene 2800 observaciones y 28 variables.

2.- Tipos de variables

```
str(x)

## 'data.frame': 2800 obs. of 28 variables:
## $ A1 : int 2 2 5 4 2 6 2 4 4 2 ...
## $ A2 : int 4 4 4 4 3 6 5 3 3 5 ...
## $ A3 : int 3 5 5 6 3 5 5 1 6 6 ...
## $ A4 : int 4 2 4 5 4 6 3 5 3 6 ...
## $ A5 : int 4 5 4 5 5 5 5 1 3 5 ...
## $ C1 : int 2 5 4 4 4 6 5 3 6 6 ...
## $ C2 : int 3 4 5 4 4 6 4 2 6 5 ...
## $ C3 : int 3 4 4 3 5 6 4 4 3 6 ...
## $ C4 : int 4 3 2 5 3 1 2 2 4 2 ...
## $ C5 : int 4 4 5 5 2 3 3 4 5 1 ...
## $ E1 : int 3 1 2 5 2 2 4 3 5 2 ...
## $ E2 : int 3 1 4 3 2 1 3 6 3 2 ...
## $ E3 : int 3 6 4 4 5 6 4 4 NA 4 ...
## $ E4 : int 4 4 4 4 4 5 5 2 4 5 ...
## $ E5 : int 4 3 5 4 5 6 5 1 3 5 ...
## $ N1 : int 3 3 4 2 2 3 1 6 5 5 ...
## $ N2 : int 4 3 5 5 3 5 2 3 5 5 ...
## $ N3 : int 2 3 4 2 4 2 2 2 2 5 ...
## $ N4 : int 2 5 2 4 4 2 1 6 3 2 ...
## $ N5 : int 3 5 3 1 3 3 1 4 3 4 ...
## $ O1 : int 3 4 4 3 3 4 5 3 6 5 ...
## $ O2 : int 6 2 2 3 3 3 2 2 6 1 ...
## $ O3 : int 3 4 5 4 4 5 5 4 6 5 ...
## $ O4 : int 4 3 5 3 3 6 6 5 6 5 ...
## $ O5 : int 3 3 2 5 3 1 1 3 1 2 ...
## $ gender : int 1 2 2 2 1 2 1 1 1 2 ...
## $ education: int NA NA NA NA NA 3 NA 2 1 NA ...
## $ age : int 16 18 17 17 17 21 18 19 19 17 ...
```

3.- Nombre de las variables

```
colnames(x)

## [1] "A1" "A2" "A3" "A4" "A5" "C1"
## [7] "C2" "C3" "C4" "C5" "E1" "E2"
## [13] "E3" "E4" "E5" "N1" "N2" "N3"
## [19] "N4" "N5" "O1" "O2" "O3" "O4"
## [25] "O5" "gender" "education" "age"
```

4.- Creación de una nueva matriz de datos en donde se incluyan las variables 1 a la 25 y las primeras 200 observaciones


```
x1 <- bfi[1:200, 1:25]
```

Matriz de correlaciones

```
R <- hetcor(x1)$correlations
```

1.- Gráfico de correlaciones

```
ggcorrplot(R, type = "lower", hc.order = TRUE)
```



En el gráfico anterior, se muestran aquellos bloques con correlaciones positivas y negativas. Los espacios en blanco indican que las variables no se correlacionan con alguna otra.

Factorización de la matriz de correlaciones

Se utiliza la prueba de esfericidad de Bartlett.

```
p_Bartlett <- cortest.bartlett(R)
```

1.- Visualización del p valor

```
p_Bartlett$p.value
```

```
## [1] 5.931663e-60
```

Con base en las siguientes hipótesis: H0: Las variables están correlacionadas. H1: Las variables no están correlacionadas.

La decisión a utilizar es: No se rechaza H0, debido a que el p-valor es pequeño, siendo que las variables están correlacionadas.

Criterio Kaiser-Meyer-Olkin

Este criterio permite verificar si los datos que se van a analizar son adecuados para un análisis factorial.

0.00 a 0.49 -> No adecuados 0.50 a 0.59 -> Poco adecuados 0.60 a 0.69 -> Aceptables 0.70 a 0.89 -> Buenos 0.90 a 1.00 -> Excelente

```
KMO(R)
```

```
## Kaiser-Meyer-Olkin factor adequacy
## Call: KMO(r = R)
## Overall MSA = 0.76
## MSA for each item =
##   A1  A2  A3  A4  A5  C1  C2  C3  C4  C5  E1  E2  E3  E4  E5  N1
## 0.66 0.77 0.69 0.73 0.75 0.74 0.79 0.76 0.76 0.74 0.80 0.81 0.79 0.81 0.83 0.70
##   N2  N3  N4  N5  O1  O2  O3  O4  O5
## 0.67 0.82 0.79 0.82 0.79 0.65 0.81 0.62 0.77
```

De acuerdo con el indicador Overall MSA = 0.76, los datos son buenos para aplicar análisis factorial.

Extracción de factores

minres: mínimo residuo mle: max verosimilitud paf: ejes principales alpha: alfa minchi: mínimos cuadrados minrak: rango mínimo

```
modelo1 <- fa(R, nfactor = 3, rotate = "none", fm = "mle")
```

```
modelo2 <- fa(R, nfactor = 3, rotate = "none", fm = "minres")
```

1.- Extracción del resultado de las Comunidades

Ahí se encuentra la proporción de la varianza explicada. Se interpreta de tal forma qué número cercanos a 1, el factor explica mejor la variable.

```
C1 <- sort(modelo1$communality, decreasing = TRUE)
```

```
C2 <- sort(modelo2$communality, decreasing = TRUE)
```

```
head(cbind(C1, C2))
```

```
##           C1           C2
## N1 0.7576920 0.6809294
## E2 0.6802809 0.6564523
## N2 0.6797943 0.5866483
## E1 0.5219674 0.5394762
## N3 0.5198285 0.4942059
## N4 0.4839516 0.4744005
```

2.- Extracción de Unidades

La unicidad es el cuadrado del coeficiente del factor único y se expresa como la proporción de la varianza explicada por el factor único. Es decir, no puede ser explicada por otros factores.

```
u1 <- sort(modelo1$uniquenesses, decreasing = TRUE)
```


```
u2 <- sort(modelo2$uniquenesses, decreasing = TRUE)
```

```
head(cbind(u1, u2))
```

```
##           u1           u2
## O2 0.9460554 0.9293483
## A4 0.8928892 0.8908844
```

```
## A1 0.8607240 0.8822080
## O5 0.8533481 0.8272041
## C5 0.8136600 0.7931685
## O1 0.7986908 0.7904667
```





```
scree(R)
```



Rotación de la matriz

```
library(GPARotation)
```

```
rot <- c("None", "Varimax", "Quartimax", "Promax")
bi_mod <- function(tipo) {
  biplot.psych(fa(x1, nfactors = 2,
    fm = "minres", rotate = tipo),
    main = paste("Biplot con rotación", tipo),
    col = c(2,3,4), pch = c(21, 18, group = bfi[, "gender"]))
}
sapply(rot, bi_mod)
```



```
## $None
## NULL
##
## $Varimax
## NULL
```

```
##
## $Quartimax
## NULL
##
## $Promax
## NULL
```


Interpretación

Para esto se utiliza el gráfico de árbol.

```
modelo_varimax <- fa(R, nfactor = 5,
  rotate = "varimax",
  fm = "minres")
```

```
fa.diagram(modelo_varimax)
```

Factor Analysis



Las líneas rojas representan a las cargas negativas y las líneas negras a las cargas positivas.

Visualización de la matriz de carga rotada

```
print(modelo_varimax$loadings, cut=0)
```

```
##
## Loadings:
##      MR1    MR2    MR4    MR3    MR5
## A1  0.234  0.106 -0.422 -0.072 -0.092
## A2  0.112 -0.032  0.653  0.190  0.113
## A3  0.198  0.066  0.744  0.051  0.169
```

```

## A4  0.163 -0.048  0.413  0.137 -0.142
## A5  0.328 -0.154  0.692 -0.009  0.115
## C1  0.054  0.089  0.140  0.634  0.287
## C2  0.052  0.174  0.114  0.690  0.050
## C3  0.032  0.018  0.076  0.642  0.016
## C4 -0.058  0.087 -0.090 -0.559 -0.159
## C5 -0.241  0.228 -0.040 -0.459  0.014
## E1 -0.691 -0.006 -0.066 -0.084 -0.017
## E2 -0.713  0.345 -0.138 -0.133 -0.025
## E3  0.546  0.003  0.157 -0.008  0.221
## E4  0.522 -0.027  0.416  0.167  0.048
## E5  0.588 -0.009  0.148  0.308  0.159
## N1  0.131  0.802 -0.150 -0.074 -0.133
## N2  0.088  0.800 -0.151 -0.038 -0.008
## N3 -0.183  0.701  0.005  0.037 -0.087
## N4 -0.513  0.491 -0.006  0.004  0.034
## N5 -0.274  0.571  0.059  0.096 -0.082
## O1  0.203 -0.107  0.148  0.076  0.535
## O2 -0.099  0.096  0.144 -0.191 -0.330
## O3  0.326 -0.159  0.034  0.062  0.680
## O4 -0.240  0.122  0.169  0.105  0.548
## O5 -0.004  0.061 -0.074 -0.077 -0.636
##
##
##          MR1   MR2   MR4   MR3   MR5
## SS loadings    2.823 2.667 2.223 2.103 1.867
## Proportion Var 0.113 0.107 0.089 0.084 0.075
## Cumulative Var 0.113 0.220 0.309 0.393 0.467

```